État de l'Art du Green Federated Learning : Rapport de Recherche et Optimisation

Hakim Abdel

20 avril 2026

Résumé

L'empreinte carbone grandissante des modèles d'Intelligence Artificielle nécessite une transition vers des paradigmes distribués et éco-responsables. Ce document dresse un état de l'art approfondi du *Green Federated Learning* (GFL). En se concentrant sur les stratégies d'optimisation, ce rapport détaille la littérature scientifique, les équations de modélisation énergétique, et les métriques de référence nécessaires à la construction d'une plateforme de benchmarking avancée. Afin de rendre cette plateforme la plus verte possible, un ensemble de règles de bonne conduite est établi. Il s'appuie sur une architecture logicielle innovante permettant d'injecter des outils de mesures environnementales de manière transparente. De plus, il intègre la modélisation de l'hétérogénéité via une Double Distribution de Dirichlet, la quantification stricte des coûts réseau, et l'élargissement vers des modèles multimodaux, garantissant ainsi une plateforme de recherche rigoureuse pour repousser la frontière de Pareto entre précision, coûts de communication et empreinte carbone.

Table des matières

1 Introduction **3**

2 État de l'Art : Stratégies de FL et Optimisation **3**
2.1 Modélisation de l'hétérogénéité : La Double Distribution de Dirichlet . . . 3
2.2 L'algorithme de base : Federated Averaging (FedAvg) 4
2.3 Régularisation Proximale : FedProx 4
2.4 Optimiseurs Adaptatifs : FedAdagrad, FedYogi, FedAdam 4

3 Modélisation et Équations de Mesure Énergétique **4**
3.1 Empreinte Computationnelle Matérielle 4
3.2 Empreinte de Communication 5

4 Conception Logicielle pour le Benchmarking GFL **5**
4.1 L'Architecture via "Mixin" 5
4.2 Isolation et Déploiement en Cluster 5

5 Règles de Bonne Conduite relatives au Green Federated Learning **6**
5.1 Règle 1 : Monitorer systématiquement l'empreinte environnementale 6
5.2 Règle 2 : Ajuster intelligemment les hyperparamètres et pénaliser la divergence 6
5.3 Règle 3 : Implémenter l'Arrêt Précoce Local (Local Early Stopping) et la Robustesse 6
5.4 Règle 4 : Préparer la réduction de la charge réseau via la compression . . . 7
5.5 Règle 5 : Respecter l'isolation architecturale (Edge Computing) 7
5.6 Règle 6 : Élargissement Scientifique vers le Multimodal 7

6 Domaines d'Application Critiques **7**
6.1 Informatique Médicale (IoMT et EHR) 7
6.2 Internet des Objets Vert (GIoT) 7

7 Prochains Challenges du Domaine **8**
7.1 Gestion de l'Effet Retardataire (Stragglers) et Asynchronisme 8
7.2 Frontière de Pareto Empirique sur Données Complexes 8

8 Conclusion **8**

1 Introduction

L'entraînement des modèles d'Intelligence Artificielle (IA) génère aujourd'hui une consommation énergétique colossale. L'énergie requise par les modèles d'IA pourrait représenter plus de 30 % de la consommation énergétique mondiale d'ici 2030 [1, 10]. L'Apprentissage Fédéré (Federated Learning - FL) a été introduit pour pallier la centralisation massive des données, permettant d'entraîner des modèles directement sur des nœuds périphériques ou des clusters sans échanger les données brutes (images médicales, données de capteurs, etc.) [3, 6].

Cependant, le FL classique s'avère extrêmement énergivore. Jusqu'à 97 % des émissions de carbone du FL proviennent des calculs sur les clients et des échanges réseau continus [1]. À titre d'exemple, un entraînement fédéré à grande échelle peut générer jusqu'à 80 kg d'équivalent CO2 [1].

C'est dans ce contexte que s'inscrit la nécessité de concevoir des plateformes de benchmarking dédiées au **Green Federated Learning (GFL)**. L'objectif est de pouvoir simuler, comparer et optimiser de manière modulaire différentes stratégies (FedAvg, FedProx, FedAdam, etc.) sur des ensembles de données complexes (tels que CIFAR-10 pour la vision générale ou CheXpert pour l'imagerie médicale [4, 13]). Le défi d'optimisation consiste à trouver la frontière de Pareto idéale entre la précision du modèle, la fonction de perte, et les coûts énergétiques matériels et réseaux.

2 État de l'Art : Stratégies de FL et Optimisation

L'optimisation d'un système GFL repose fondamentalement sur le choix du framework (tel que PyTorch, privilégié pour l'imagerie médicale et la flexibilité de la recherche), de la surcouche de fédération (telle que Flower.ai pour sa gestion via gRPC), et surtout de l'algorithme d'agrégation [4]. La littérature scientifique propose plusieurs stratégies pour gérer l'hétérogénéité des données (non-IID) et des systèmes, ces deux facteurs impactant directement la consommation énergétique par l'augmentation des cycles de communication [9].

2.1 Modélisation de l'hétérogénéité : La Double Distribution de Dirichlet

Dans un environnement distribué réel, les clients ne possèdent ni la même quantité de données, ni la même répartition de classes [3]. Pour simuler cela avec précision, l'hétérogénéité est modélisée au travers d'une **Double Distribution de Dirichlet** [1]. Cette méthode sépare la génération du déséquilibre en deux paramètres α distincts :

- **Le déséquilibre quantitatif (Quantity Skew) :** Un paramètre contrôle le volume de données attribué à chaque client.
- **Le déséquilibre des labels (Feature/Label Skew) :** Un second paramètre contrôle la répartition des classes, permettant de simuler une hétérogénéité extrême (non-IID sévère) [1].

2.2 L'algorithme de base : Federated Averaging (FedAvg)

La méthode de référence, *FedAvg*, consiste pour le serveur à effectuer une moyenne pondérée des poids des clients [6]. Très efficace en termes de calcul pur, cette méthode souffre d'une forte perte de performance sur des données non-IID (données non identiquement distribuées). Il a été démontré que la précision peut chuter jusqu'à 55 % sur des réseaux de neurones convolutifs (CNN) fortement hétérogènes [9]. Ce ralentissement de la convergence contraint le système à multiplier les communications, gaspillant ainsi une quantité massive d'énergie [1].

2.3 Régularisation Proximale : FedProx

Pour contrer la divergence des modèles locaux induite par les données non-IID, la stratégie *FedProx* introduit une variable de proximité μ lors de l'optimisation locale côté client [7]. La fonction de perte locale modifiée s'écrit :

$$h_k(w; w^t) = F_k(w) + \frac{\mu}{2}||w - w^t||^2 \tag{1}$$

En ajustant μ (un hyperparamètre critique à configurer sur une plateforme d'optimisation), le modèle local est contraint de rester proche du modèle global w^t. Un μ faible réduit la charge de calcul mais ralentit la convergence globale. Trouver le μ optimal est une étape clé du Green FL pour minimiser les itérations de communication.

2.4 Optimiseurs Adaptatifs : FedAdagrad, FedYogi, FedAdam

Pour gérer les gradients bruités causés par l'hétérogénéité, l'utilisation de taux d'apprentissage adaptatifs côté serveur a été proposée [8]. Ces stratégies (FedAdam, FedYogi) convergent généralement plus vite que FedAvg, réduisant ainsi le temps de réseau. Néanmoins, elles exigent le stockage de moments adaptatifs côté serveur, augmentant la complexité et la charge mémoire, ce qui implique un compromis *Performance-Per-Watt* (PPW) à surveiller [1].

3 Modélisation et Équations de Mesure Énergétique

Le passage de l'Apprentissage Fédéré au Green Apprentissage Fédéré nécessite la quantification rigoureuse de la consommation d'énergie et des émissions de CO2. Une plateforme de benchmarking avancée doit intégrer des outils de suivi (tels que CodeCarbon) pour mesurer l'empreinte matérielle et réseau [11, 12].

3.1 Empreinte Computationnelle Matérielle

Les sondes matérielles permettent une mesure dynamique du processeur et de la carte graphique. Cependant, la mémoire RAM n'ayant souvent pas de sonde de consommation dynamique logicielle accessible, la modélisation standard pour estimer la puissance statique de la RAM s'appuie sur l'équation suivante :

$$P_{RAM} = \text{Taille de la RAM (Go)} \times 0.375\,\text{Watts} \tag{2}$$

L'énergie totale de calcul pour un cycle d'entraînement local E_{comp} se calcule alors par l'intégration de la puissance sur le temps d'entraînement Δt :

$$E_{comp} = \int_0^{\Delta t} \Big(P_{CPU}(t) + P_{GPU}(t) + P_{RAM} \Big) \, dt \tag{3}$$

3.2 Empreinte de Communication

Dans les architectures basées sur des appels de procédure à distance (comme gRPC), la sérialisation des poids du modèle génère une charge réseau critique. Le volume de données total transféré (en Mégaoctets) est calculé de manière déterministe via la formule suivante [5] :

$$V_{total} = 2 \times |w| \times K_{sel} \times R \tag{4}$$

Où $|w|$ est le poids du modèle, K_{sel} le nombre de clients sélectionnés, R le nombre de rounds, et le multiplicateur 2 représente les flux montants et descendants.

L'énergie consommée E_{Tr} pour transmettre ces données (converties en l bits) sur une distance d est ensuite modélisée par l'équation suivante [2] :

$$E_{Tr}(l, d) = \begin{cases} l(Ee + E_{fs} \cdot d^2), & \text{si } d \leq d_t \\ l(Ee + E_{amp} \cdot d^4), & \text{si } d > d_t \end{cases} \tag{5}$$

Où Ee est l'énergie de base de transmission, et E_{fs} / E_{amp} sont les énergies d'amplification selon la distance seuil d_t.

4 Conception Logicielle pour le Benchmarking GFL

Déployer une plateforme de recherche capable d'évaluer ces métriques requiert une ingénierie logicielle spécifique pour concilier la nature distribuée du FL et le besoin de centralisation des mesures.

4.1 L'Architecture via "Mixin"

L'un des défis techniques majeurs avec les frameworks de FL est l'impossibilité d'injecter des outils de suivi environnemental sans devoir réécrire entièrement le code source de chaque stratégie d'agrégation. La solution conceptuelle optimale est l'utilisation de la programmation orientée objet via un Mixin. Ce concept repose sur l'héritage multiple :

- Le Mixin intercepte la méthode centrale d'agrégation.
- Il injecte dynamiquement le déclenchement du suivi carbone et la journalisation des métriques (Précision, Perte, CO2eq).
- Il fait ensuite appel à la méthode parente pour exécuter la logique mathématique propre à la stratégie choisie.

Cette conception garantit un code modulaire et permet d'évaluer l'impact énergétique de toute nouvelle stratégie simplement en héritant de cette classe.

4.2 Isolation et Déploiement en Cluster

La simulation de clients locaux sur une machine unique biaise les mesures énergétiques. Le déploiement sur des nœuds de calcul isolés est recommandé [2, 14]. L'utilisation

d'un planificateur de tâches pour clusters (tel que Slurm) permet d'allouer un nœud physique par client. Cette architecture garantit que la consommation mesurée sur un nœud correspond exclusivement au processus d'entraînement de ce client spécifique, simulant fidèlement un environnement distribué.

5 Règles de Bonne Conduite relatives au Green Federated Learning

Dans le but d'optimiser le maximum d'énergie et de rendre la plateforme développée la plus verte possible, un ensemble de règles de bonne conduite a été établi. Ces règles dictent l'utilisation et l'évolution de la plateforme de benchmarking.

5.1 Règle 1 : Monitorer systématiquement l'empreinte environnementale

Une IA ne peut être qualifiée de "verte" si son impact n'est pas mesuré. La règle fondamentale impose que toute expérience lancée sur la plateforme soit couplée à un suivi rigoureux. L'utilisation transparente de l'architecture par "Mixin" garantit que la consommation matérielle et les émissions de carbone sont générées sous forme d'artefacts. La plateforme doit impérativement générer en fin d'entraînement un rapport PDF lisible automatisé, synthétisant l'empreinte CO2 et le coût réseau global.

5.2 Règle 2 : Ajuster intelligemment les hyperparamètres et pénaliser la divergence

Il est proscrit de lancer des entraînements à l'aveugle. L'utilisateur doit justifier le choix de son algorithme face à la Double Distribution de Dirichlet.

- Face à des données hétérogènes, il convient de privilégier des stratégies adaptatives (FedProx, FedAdam) pour éviter un gaspillage d'énergie lié à une non-convergence.
- Le terme proximal μ de FedProx doit être minutieusement calibré via l'interface : une valeur optimale permet de réduire le nombre d'itérations nécessaires entre les clients et le serveur [7].

5.3 Règle 3 : Implémenter l'Arrêt Précoce Local (Local Early Stopping) et la Robustesse

Afin de préserver les ressources CPU des nœuds d'entraînement, il est recommandé d'activer des mécanismes d'interruption dynamique. Si un client local constate que sa fonction de perte ne s'améliore plus, il doit pouvoir interrompre le calcul et renvoyer ses poids prématurément [1]. De plus, le système doit garantir une gestion des sessions (historique des *Runs*) et intégrer une tolérance aux pannes pour résister aux déconnexions brutales des nœuds (effet retardataire) sans faire crasher l'expérience.

5.4 Règle 4 : Préparer la réduction de la charge réseau via la compression

La transmission de modèles lourds sature la bande passante et représente un gouffre énergétique. La bonne conduite impose d'intégrer des mécanismes de compression :

— **La Quantification :** Réduire la précision des poids (passer de 32 bits à 8 bits) avant la transmission pour alléger le volume de données [15, 16].

— **La Sparsification :** N'envoyer au serveur central que les gradients ayant subi les modifications les plus significatives.

5.5 Règle 5 : Respecter l'isolation architecturale (Edge Computing)

La validation énergétique n'a de sens que si l'architecture réseau simule la réalité. La règle impose d'utiliser le gestionnaire de cluster pour distribuer physiquement la charge. Cette hybridation avec l'Edge Computing garantit que l'énergie mesurée reflète le véritable coût du déploiement sur des capteurs ou serveurs d'hôpitaux [2].

5.6 Règle 6 : Élargissement Scientifique vers le Multimodal

Bien que la classification d'images soit un standard, une plateforme de benchmarking GFL ambitieuse se doit d'évaluer la consommation sur des formats variés. L'implémentation de modèles pour les données tabulaires et les séries temporelles (LSTM, GRU), ainsi que l'exploration expérimentale de modèles multimodaux (tels que CLIP pour le traitement simultané de textes et d'images), sont des axes obligatoires pour valider la flexibilité énergétique du système.

6 Domaines d'Application Critiques

L'optimisation des architectures FL bénéficie directement aux domaines où la confidentialité des données est une barrière absolue, et où les dispositifs sont contraints en énergie.

6.1 Informatique Médicale (IoMT et EHR)

L'application du FL sur les Dossiers Médicaux Électroniques (EHR) ou l'imagerie médicale est cruciale [3]. Des ensembles de données de référence (tels que CheXpert pour la détection de pathologies thoraciques) exigent des modèles très lourds [4, 13]. Appliquer les règles du GFL via la plateforme de benchmarking permet d'ajuster les hyperparamètres pour minimiser la consommation des serveurs hospitaliers sans risquer de dégrader la précision des diagnostics.

6.2 Internet des Objets Vert (GIoT)

Dans les réseaux de capteurs environnementaux ou les villes intelligentes, les appareils possèdent des batteries limitées. Il a été démontré que l'Apprentissage Fédéré déployé en périphérie (Edge FL) permet de réduire l'énergie globale du système de 15 % à 35 % en rapprochant le traitement des données de leur source [2].

7 Prochains Challenges du Domaine

Le développement de plateformes d'optimisation met en lumière les futurs verrous scientifiques de l'IA éco-responsable.

7.1 Gestion de l'Effet Retardataire (Stragglers) et Asynchronisme

Dans un réseau hétérogène, certains clients terminent leur itération plus tard que les autres. Dans une architecture FL synchrone, le serveur central reste inactif en attente, consommant de l'énergie statique inutilement. Le passage vers des algorithmes asynchrones est la prochaine évolution majeure pour supprimer ce gaspillage [17, 18].

7.2 Frontière de Pareto Empirique sur Données Complexes

Le défi technologique consiste à tester empiriquement à quel niveau de compression (Quantification/Sparsification) la précision médicale subit une dégradation critique inacceptable [16]. L'objectif est d'utiliser la plateforme pour tracer cette ligne de bascule et identifier les réglages optimaux garantissant un modèle viable et une consommation électrique drastiquement réduite.

8 Conclusion

Le Green Federated Learning représente la convergence indispensable entre la protection de la confidentialité des données et l'impératif climatique. La conception de plateformes de benchmarking distribuées — combinant des frameworks modulaires, un suivi granulaire des émissions, et des architectures logicielles élégantes — est l'étape fondatrice pour évaluer scientifiquement les algorithmes.

L'application stricte des règles de bonne conduite définies pour la plateforme (suivi du bilan carbone, ajustement intelligent des hyperparamètres, isolation des nœuds sur cluster et préparation à la compression) permet de rendre cette infrastructure la plus verte possible. Les futurs travaux en asynchronisme permettront de démocratiser le déploiement de ces intelligences artificielles sur l'Internet des Objets (IoT) et dans les milieux médicaux, sans compromettre la durabilité environnementale.

Références

[1] D. Thakur, A. Guzzo, G. Fortino, et F. Piccialli, « Green Federated Learning : A New Era of Green Aware AI », *ACM Comput. Surv.*, vol. 57, no 8, Article 194, 2025.

[2] J. B. Awotunde et al., « FL_GIoT : Federated Learning Enabled Edge-Based Green Internet of Things System : A Comprehensive Survey », *IEEE Access*, vol. 11, 2023.

[3] B. Pfitzner, N. Steckhan, et B. Arnrich, « Federated Learning in a Medical Context : A Systematic Literature Review », *ACM Trans. Internet Technol.*, vol. 21, no 2, Article 50, 2021.

[4] J. Xu et al., « Federated Learning for Healthcare Informatics », *Journal of Healthcare Informatics Research*, vol. 5, pp. 1-19, 2021.

[5] J. Konečný, H. B. McMahan, F. X. Yu, P. Richtárik, A. T. Suresh, et D. Bacon, « Federated learning : Strategies for improving communication efficiency », *arXiv :1610.05492*, 2016.

[6] H. B. McMahan, E. Moore, D. Ramage, S. Hampson, et B. A. y Arcas, « Communication-efficient learning of deep networks from decentralized data », *AISTATS*, 2017.

[7] T. Li, A. K. Sahu, M. Zaheer, M. Sanjabi, A. Talwalkar, et V. Smith, « Federated optimization in heterogeneous networks (FedProx) », *Proceedings of Machine learning and systems*, 2020.

[8] S. Reddi et al., « Adaptive federated optimization (FedYogi/FedAdam/FedAdagrad) », *arXiv :2003.00295*, 2020.

[9] Y. Zhao, M. Li, L. Lai, N. Suda, D. Civin, et V. Chandra, « Federated learning with non-IID data », *arXiv :1806.00582*, 2018.

[10] C.-J. Wu et al., « Sustainable AI : Environmental implications, challenges and opportunities », *Proceedings of Machine Learning and Systems*, 2022.

[11] A. Lacoste, A. Luccioni, V. Schmidt, et T. Dandres, « Quantifying the carbon emissions of machine learning », *arXiv :1910.09700*, 2019.

[12] B. Courty et al., « mlco2/codecarbon », *Zenodo*, 2024.

[13] J. Irvin et al., « CheXpert : A large chest radiograph dataset with uncertainty labels and expert comparison », *AAAI*, 2019.

[14] W. Y. B. Lim et al., « Federated learning in mobile edge networks : A comprehensive survey », *IEEE Communications Surveys & Tutorials*, 2020.

[15] G. Chen et al., « NQFL : Nonuniform quantization for communication efficient federated learning », *IEEE Communications Letters*, 2024.

[16] S. M. Shah et V. K. N. Lau, « Model compression for communication efficient federated learning », *IEEE Transactions on Neural Networks and Learning Systems*, 2023.

[17] B. Askin, P. Sharma, C. Joe-Wong, et G. Joshi, « FedAST : Federated asynchronous simultaneous training », *UAI*, 2024.

[18] C. Xie, S. Koyejo, et I. Gupta, « Asynchronous federated optimization », *arXiv :1903.03934*, 2019.